

Proyecto Final: Precios de SUVs

Ignacio Vargas, Ivo Vecchietti

Abstract—El presente trabajo surge de la necesidad de estimar de forma automatizada el precio de vehículos tipo SUV publicados en plataformas de compraventa como Mercado Libre, un problema de interés tanto para vendedores como para compradores. Para abordar esta tarea, se utilizó un enfoque de aprendizaje automático basado en un pipeline de procesamiento que incluye limpieza de datos, imputación, codificación de variables categóricas y escalado. Se entrenaron y compararon distintos modelos de regresión, entre ellos Gradient Boosting Regressor y CatBoost, y se seleccionó el modelo final en función de su desempeño en un conjunto de test, medido mediante el error cuadrático medio (RMSE) y el coeficiente de determinación R^2 . Los resultados obtenidos muestran una buena capacidad predictiva según ambas métricas, lo que demuestra la utilidad del enfoque adoptado.

Index Terms—Machine Learning, regresión, CatBoost, Gradient Boosting, vehículos SUV, predicción de precios, RMSE.

1 INTRODUCCIÓN

En los últimos años, la compraventa de vehículos a través de plataformas digitales como Mercado Libre ha ganado protagonismo en el mercado argentino. En este contexto, disponer de herramientas que permitan estimar el precio justo de un vehículo resulta de gran utilidad tanto para compradores como para vendedores. La predicción automática de precios en función de las características del vehículo es, por lo tanto, un problema de relevancia práctica y comercial.

El presente informe tiene como finalidad exponer el trabajo llevado a cabo, el cual aborda este problema utilizando técnicas de aprendizaje automático. Se emplea un conjunto de datos con publicaciones reales de vehículos tipo SUV extraídas de Mercado Libre Argentina entre el 13 y el 30 de mayo de 2025. Cada registro contiene información relevante como la marca, modelo, año, versión, color, tipo de combustible, puertas, transmisión, motor, tipo de carrocería, con cámara de retroceso, kilómetros, título, moneda, descripción, tipo de vendedor y el precio, que es la variable objetivo a predecir.

La entrada de nuestro algoritmo es un conjunto de atributos del vehículo y la salida es una predicción del precio en dólares. Para modelar esta relación, implementamos un pipeline de regresión que incluye preprocesamiento de datos (limpieza, imputación de valores faltantes, codificación de variables categóricas y normalización) seguido del entrenamiento de modelos de regresión. En particular, exploramos el uso de regresores como GradientBoost Regressor y CatBoost Regressor, evaluando su desempeño mediante el error cuadrático medio (RMSE) y el coeficiente de determinación R^2 sobre un conjunto de test.

El objetivo general del proyecto fue construir un modelo robusto y reproducible, capaz de generalizar a nuevos datos, ofreciendo estimaciones de precios razonables y útiles desde el punto de vista práctico.

2 CONJUNTO DE DATOS Y CARACTERÍSTICAS

El conjunto de datos utilizado corresponde a publicaciones de vehículos tipo SUV. La información incluye tanto características técnicas de los vehículos (marca, modelo, año, transmisión, cantidad de puertas, motorización, entre otros) como metadatos de las publicaciones.

Luego de una limpieza inicial y eliminación de valores extremos, el dataset fue dividido en tres subconjuntos: entrenamiento, validación y prueba, manteniendo una proporción de 64% / 16% / 20%, respectivamente. La cantidad de ejemplos resultante en cada subconjunto, una vez eliminados los outliers y aplicado el aumento de datos, fue de aproximadamente X (entrenamiento), Y (validación) y Z (prueba)¹.

Durante el preprocesamiento se realizaron varias transformaciones:

- Conversión de precios a USD usando la tasa actual obtenida de la API de Bluelytics.
- Eliminación y/o reemplazo de valores absurdos o inconsistentes en variables como Año y Puertas.
- Imputación de valores faltantes utilizando métodos basados en KNN (KNNImputer) con $k = 5$, tanto para variables categóricas codificadas como para la cantidad de puertas.
- Limpieza y estandarización de campos categóricos como Color, Marca y Modelo, usando funciones de normalización y coincidencia difusa (fuzzy matching).
- Generación de variables derivadas como Edad del vehículo, logaritmo de los kilómetros, y la razón km/año.
- Se eliminaron las columnas Título y Descripción por no aportar valor predictivo tras su codificación.

Las variables categóricas fueron codificadas utilizando un esquema de *Label Encoding* y *frecuencia suavizada*, mediante un codificador personalizado basado en conteo con smoothing (tipo Laplace). Este enfoque permitió evitar el

• Estudiantes de la Universidad de San Andrés.

1. Reemplazar con los valores reales

sobreajuste en categorías poco frecuentes y manejar adecuadamente valores nuevos en validación y prueba.

El conjunto final de características incluyó variables numéricas (Año, Puertas, Kilómetros, Edad, log_km) y diversas variables categóricas transformadas a frecuencias y etiquetas (Marca, Modelo, Versión, Tipo de vendedor, entre otras).

3 METODOLOGÍA

En este trabajo se planteó el problema de regresión sobre precios de vehículos como una tarea supervisada, donde el objetivo es predecir el precio de una publicación a partir de diversas características técnicas y contextuales del vehículo. Dado que la variable `Precio` presenta una distribución altamente sesgada hacia la derecha, se decidió aplicar una transformación logarítmica natural sobre la variable objetivo para estabilizar la varianza, reducir la influencia de valores extremos y facilitar el aprendizaje de patrones. Todos los modelos fueron entrenados sobre esta variable transformada, y sus predicciones fueron luego deslogarimizadas para interpretar los resultados en términos de precios reales (USD).

Se implementaron dos modelos de regresión con diferente complejidad y capacidad expresiva: un modelo de boosting con árboles de regresión, y un modelo de boosting avanzado con técnicas específicas para datos tabulares. A continuación se describen sus fundamentos.

Gradient Boosting Regressor (GBR)

El primer modelo utilizado fue un *Gradient Boosting Regressor*, un algoritmo de ensamblado secuencial de modelos débiles (árboles de decisión) donde cada nuevo modelo busca corregir los errores del anterior. Formalmente, el modelo construye una función predictiva como suma de funciones base:

$$F_0(x) = \arg \min_c \sum_{i=1}^n (y_i - c)^2, \quad F_m(x) = F_{m-1}(x) + \gamma_m h_m(x)$$

donde $h_m(x)$ es un árbol de regresión entrenado sobre los residuos $r_i^{(m)} = y_i - F_{m-1}(x_i)$, y γ_m es una tasa de aprendizaje que controla la contribución de cada nuevo árbol. Este proceso iterativo se repite M veces hasta alcanzar el número deseado de árboles.

Se utilizó `GradientBoostingRegressor` de `scikit-learn`, junto con `RandomizedSearchCV` para explorar combinaciones de hiperparámetros como la profundidad máxima de los árboles, el número de estimadores, la tasa de aprendizaje y la fracción de muestras utilizada por cada árbol. El boosting es una de las técnicas más efectivas para problemas de regresión no lineal, especialmente en datos estructurados.

CatBoost Regressor

El segundo modelo considerado fue `CatBoostRegressor`, un algoritmo de boosting de gradiente desarrollado por Yandex que introduce varias mejoras con respecto a implementaciones estándar como `XGBoost` o `LightGBM`, especialmente en el manejo eficiente de variables categóricas y en

la reducción del sobreajuste sin requerir preprocesamiento intensivo.

Al igual que otros métodos de boosting, CatBoost entrena una secuencia de árboles de decisión, donde cada nuevo árbol se ajusta para corregir los errores residuales del modelo anterior. Sin embargo, introduce varias innovaciones clave que serán desarrolladas a continuación.

Ordered Boosting: para evitar el *target leakage* (filtración de información del futuro al pasado), CatBoost calcula las estadísticas necesarias para variables categóricas utilizando únicamente ejemplos previos en un orden aleatorio fijo. De esta forma, al construir los árboles en el paso m , se utilizan estadísticas calculadas sin haber visto los targets del mismo paso, emulando un entorno de validación cruzada implícito y reduciendo el riesgo de sobreajuste.

Random Permutations: CatBoost genera varias permutaciones aleatorias del dataset de entrenamiento para construir diferentes representaciones internas de las variables categóricas, lo que mejora la robustez del modelo y estabiliza las estimaciones de frecuencia condicional. Cada permutación permite calcular estadísticas como medias targetizadas sin violar la causalidad.

Shrinkage progresivo: similar al aprendizaje por etapas, esta técnica ajusta la contribución de cada árbol agregando un factor de decaimiento. A medida que se avanza en la secuencia de boosting, la influencia de los nuevos árboles se reduce progresivamente, lo que ayuda a evitar el sobreajuste.

Bagging Temperature: controla cuánta aleatoriedad se introduce al seleccionar subconjuntos de datos para entrenar cada árbol. Un valor alto introduce más diversidad (similitud con bagging), mientras que un valor bajo mantiene más determinismo. Es un parámetro de regularización que permite encontrar un balance entre sesgo y varianza.

Optimización bayesiana: para seleccionar los hiperparámetros del modelo, se utilizó `BayesSearchCV`, que implementa optimización bayesiana. Este método modela el desempeño del modelo como una función probabilística del espacio de hiperparámetros, y elige nuevas combinaciones a evaluar basándose en el trade-off entre exploración y explotación. Es más eficiente que la búsqueda aleatoria o en grid, ya que aprende dónde buscar a medida que avanza.

Estas características convierten a CatBoost en una opción robusta y precisa para tareas de regresión sobre datos tabulares, especialmente cuando se trabaja con múltiples variables categóricas y relaciones complejas entre variables. Se incorporó por su reconocida efectividad y porque permite reducir el trabajo de ingeniería de características al manejar internamente el tratamiento de categorías.

4 EXPERIMENTOS, RESULTADOS Y DISCUSIÓN

4.1 Análisis exploratorio y componentes adicionales

Análisis por color

Se realizó un análisis exploratorio del impacto del color en el precio, visualizando la distribución promedio de precios para cada tonalidad.

El gráfico de la Figura 1 muestra la relación entre el color del vehículo y su precio mediano en dólares. Se observa que colores más neutros como Gris, Azul y Blanco están asociados a precios medianos más altos, lo cual puede




Fig. 1. Precio mediano por color del vehículo.

deberse a su mayor demanda o a que suelen encontrarse en versiones más modernas o equipadas. En contraste, colores menos frecuentes como Dorado o Raro tienden a tener precios más bajos, posiblemente por menor popularidad o menor cantidad de datos representativos.

Análisis por tipo de vendedor

Se examinó la relación entre el tipo de vendedor (concesionaria, particular, agencia) y el precio promedio de las publicaciones.




Fig. 2. Precio mediano según tipo de vendedor.

La Figura 2 compara el precio mediano según el tipo de vendedor. Se observa que los vehículos ofrecidos por *concesionarios oficiales* presentan precios significativamente más altos que los de vendedores particulares o agencias. Esto es esperable, ya que los concesionarios suelen ofrecer unidades más nuevas, con garantía o certificadas. Esta información resulta útil tanto para segmentar el mercado como para enriquecer modelos de predicción.

4.1.1 Efecto del tiempo y uso en el precio

La Figura 3 muestra cómo se relacionan la edad del vehículo con el precio en USD. La Figura 4 muestra como se relacionan los km acumulados del vehículo con el precio del mismo. En ambos casos se observa una relación inversa: a mayor antigüedad o mayor kilometraje, menor es el precio. Sin embargo, la dispersión es considerable, especialmente en unidades muy usadas, lo que sugiere que otras variables




Fig. 3. Relación entre edad y precio




Fig. 4. Relación entre Km y precio

también influyen significativamente (como marca, versión, etc.). Estas observaciones motivaron la inclusión de variables como edad, $\log(\text{km})$ y su producto cruzado en los modelos entrenados.

4.2 Hiperparámetros y Configuración Experimental

Para abordar la tarea de regresión sobre precios de vehículos SUV, se entrenaron y compararon dos modelos de *gradient boosting*: **Gradient Boosting Regressor (GBR)** y **Cat-Boost Regressor**, ambos optimizados mediante búsqueda de hiperparámetros. En ambos casos se utilizaron técnicas de validación cruzada para seleccionar los mejores valores.

Gradient Boosting Regressor (GBR)

Se utilizó validación cruzada con **10 folds**, combinada con `GridSearchCV` para explorar 20 combinaciones de hiperparámetros. Los mejores parámetros obtenidos fueron:

- `n_estimators`: 800
- `learning_rate`: 0.1
- `max_depth`: 5
- `min_samples_leaf`: 20
- `subsample`: 1.0

CatBoost Regressor

Para CatBoost, se utilizó una búsqueda bayesiana con `BayesSearchCV`, utilizando **5 folds** en la validación cruzada. Los mejores hiperparámetros obtenidos fueron:

- `iterations`: 1574
- `depth`: 8
- `learning_rate`: 0.0597
- `l2_leaf_reg`: 18
- `bagging_temperature`: 0.799
- `border_count`: 130
- `subsample`: 0.77

4.3 Métricas de Evaluación

Dado que se trata de un problema de regresión, las métricas utilizadas fueron:

4.3.0.1 Root Mean Squared Error (RMSE)::

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

4.3.0.2 Coeficiente de determinación (R^2)::

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Estas métricas permiten cuantificar la precisión general del modelo (RMSE) y qué proporción de la varianza de los precios puede ser explicada por los predictores (R^2).

4.4 Resultados Cuantitativos

Los resultados obtenidos se resumen en las siguientes tabla:

Modelo	RMSE (USD)	R^2
GBR	4,146	0.919
CatBoost	4,232	0.915

TABLE 1

Comparación de métricas en el conjunto de validación.

Modelo	RMSE (USD)	R^2
GBR	3,834	0.930
CatBoost	4,030	0.923

TABLE 2

Comparación de métricas en el conjunto de test.

4.5 Resultados Cualitativos y Visualización

Predicción vs Realidad (GBR)

La Figura 5 muestra un gráfico de dispersión entre el precio real y el precio predicho por el modelo GBR sobre el set de validación y la Figura 6 replica esto sobre el set de testeo.

Se observa que:

- El modelo predice correctamente la mayoría de los vehículos en el rango de precios bajos a medios




Fig. 5. Precio predicho vs. precio real para el modelo GBR (val).




Fig. 6. Precio predicho vs. precio real para el modelo GBR (test).

(10,000 a 60,000 USD), con alta concentración sobre la diagonal.

- En vehículos de alto valor (más de 80,000 USD), se observan mayores errores, tanto por sobreestimación como por subestimación.
- Esto sugiere una menor precisión en vehículos de alta gama, posiblemente por escasez de datos representativos.

Importancia de Features (CatBoost)

La Figura 7 muestra las 20 variables más importantes según el modelo CatBoost.




Fig. 7. Top 20 variables más importantes según CatBoost.

Entre las variables más relevantes se destacan:

- **Transmission_code:** Tiene el mayor impacto en el precio, probablemente por su asociación con el tipo de vehículo y equipamiento.
- **Edad y Edad_x_logkm:** Indicadores clave de antigüedad y uso.
- **Versión_Trim_freq, Marca_freq y Modelo_freq:** Reflejan la influencia de configuraciones específicas y popularidad.
- Otras variables como el color o la cantidad de puertas tienen menor influencia, lo cual es razonable.

4.6 Discusión y Sobreajuste

Ambos modelos muestran un desempeño muy alto en validación, con valores de R^2 mayores a 0.91. Para reducir el riesgo de *overfitting*, se adoptaron las siguientes estrategias:

- División clara de los conjuntos de entrenamiento, validación y test usando `train_test_split`, evitando leakage.
- Regularización explícita mediante hiperparámetros como `min_samples_leaf` en GBR y `l2_leaf_reg` en CatBoost.
- Uso de `subsample` en CatBoost para introducir aleatoriedad y reducir el sobreajuste.
- Inclusión de solo las variables con relevancia informativa, descartando features irrelevantes o redundantes.

No obstante, los errores observados en los valores extremos podrían estar vinculados a una baja representatividad en esos rangos. Para mejorar este aspecto, podría implementarse un entrenamiento focalizado en muestras de alto valor o penalizar más los errores grandes durante el entrenamiento.

5 CONCLUSIÓN Y TRABAJO FUTURO

En este trabajo se abordó el problema de estimar el precio de vehículos tipo SUV utilizando técnicas de aprendizaje

automático aplicadas sobre datos reales provenientes de publicaciones online. A través de un pipeline robusto de procesamiento y modelado, se exploraron y compararon distintos algoritmos de regresión, entre ellos Ridge Regression (descartado por mal ajuste), CatBoost Regressor y Gradient Boosting Regressor, siendo este último el que presentó el mejor desempeño tanto en la métrica de error (RMSE) como en capacidad explicativa (R^2), alcanzando un valor de $R^2 = 0.916$ sobre el conjunto de validación y $RMSE = 4,267$ USD, e incluso mejores resultados sobre el conjunto de test.

Los buenos resultados obtenidos demuestran que el enfoque propuesto es capaz de modelar relaciones no lineales complejas entre las características del vehículo y su precio, incluso sin una ingeniería de variables excesiva gracias al poder expresivo de los modelos de boosting. Además, se evidenció que las variables más influyentes para la predicción están asociadas a la transmisión, la antigüedad, y la versión específica del vehículo, lo cual resulta coherente con el dominio.

Como trabajo futuro, sería interesante experimentar con arquitecturas de modelos aún más sofisticadas como Light-GBM o redes neuronales específicas para datos tabulares (como TabNet), así como incorporar descripciones textuales mediante técnicas de procesamiento de lenguaje natural (NLP). También se podría evaluar la estabilidad del modelo en el tiempo con datos de otras temporadas del año, analizar el impacto de variables macroeconómicas, o incluso construir un sistema interactivo de recomendación de precios para usuarios finales. Finalmente, disponer de un set de datos con más ejemplos de vehículos de alta gama podría ayudar a reducir los errores observados en ese segmento.